

Headline

大家好：

这是2018年度第10篇Arxiv Weekly。

本文是 模型架构 方向的文章。

Highlight

提出AmoebaNet，最近的ImageNet Backbone，达到83.9%/96.6%的t1/t5 acc

Information

Title

Regularized Evolution for Image Classifier Architecture Search

Link

<https://arxiv.org/pdf/1802.01548.pdf>

Source

- 谷歌（Google Brain）[Quoc V.Le 组]

Introduction

在手工设计图像分类神经网络的过程中，得到了许多成果。这些成果中具有指导性的部分启发了NAS技术的诞生。之前的主流NAS是通过RL进行搜索空间内的网络结构遍历实现的。

另一方面，通过启发式算法中的进化算法进行分类网络生成的努力从未停止，但是生成的网络结构都不能和手工设计的优秀网络相比。

本文通过进化算法给出了up-to-date的分类网络AmoebaNet。首次，**evolution aided NAS outperformed**了传统手工设计网络。在ImageNet上，大规模的AmoebaNet-A（469M）实现了83.9%/96.6%的t1/t5 acc；而**comparable**规模的AmoebaNet-A（87M）也达到了82.8%/96.1%的t1/t5 acc。

通过控制变量实验，我们证明了本文提出的进化算法相比于RL算法复杂度更低，而且能够更早给出可靠的网络结构。故而，本文提出的进化算法是更简单高效的new NAS technology。

Keys

1. 本文的亮点

经典的进化学习方法（*neuro-evolution of topologies*）并不能生成足够优秀的网络结构。为了改变这样的情况，本文提出了两个改进点，使得算法搜索的结果得到了革新：

- Adding ages。文章对之前最好的 *tournament selection evolutionary* 算法进行了改变，使得**tournament**的结果更偏向**younger genotypes**。可以看到这样的策略改变带来了非常关键的性能提升。

- Using NASNet search space。文章采用了最简化的变异（mutation）方法，使得整个进化过程能够被约束在NASNet的搜索空间中，等于更好地利用先验网络知识。

Algorithm 1 Aging Evolution

```

population  $\leftarrow$  empty queue  $\triangleright$  The population.
history  $\leftarrow \emptyset$   $\triangleright$  Will contain all models.
while  $|population| < P$  do  $\triangleright$  Initialize population.
    model.arch  $\leftarrow$  RANDOMARCHITECTURE()
    model.accuracy  $\leftarrow$  TRAINANDEVAL(model.arch)
    add model to right of population
    add model to history
end while
while  $|history| < C$  do  $\triangleright$  Evolve for  $C$  cycles.
    sample  $\leftarrow \emptyset$   $\triangleright$  Parent candidates.
    while  $|sample| < S$  do
        candidate  $\leftarrow$  random element from population
         $\triangleright$  The element stays in the population.
        add candidate to sample
    end while
    parent  $\leftarrow$  highest-accuracy model in sample
    child.arch  $\leftarrow$  MUTATE(parent.arch)
    child.accuracy  $\leftarrow$  TRAINANDEVAL(child.arch)
    add child to right of population
    add child to history
    remove dead from left of population  $\triangleright$  Oldest.
    discard dead
end while
return highest-accuracy model in history
  
```

文章的进化算法如上图所示。

2. 对NASNet搜索空间的解释

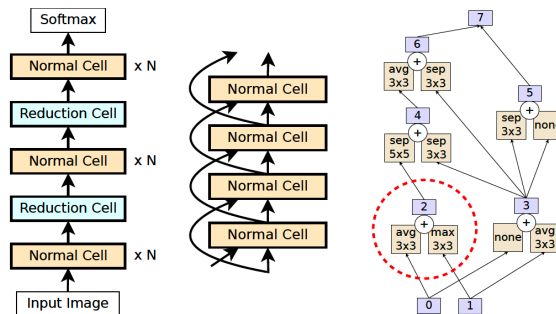


Figure 1: NASNet Search Space [53]. LEFT: the full outer structure (omitting skip inputs for clarity). MIDDLE: detailed view with the skip inputs. RIGHT: cell example. Dotted line demarcates a pairwise combination.

上图左侧可以看到NASNet搜索空间的共性结构，本文中的AmoebaNet在这个空间中生成，自然沿用了同样的结构。

其中normal cell全部使用skip connection的方式连接；reduction cell和normal cell只有两个不同：其一是训练独立故具体样式不同；其二是reduction cell的末尾会做一次stride=2的downsample，使得每个feature map大小变为原本的1/4。

启发式的网络生成采用“五步断肠”的原则，也即有且只有5次可选择的操作，每次操作合并两个结点。5次操作完成后，所有叶子节点被强行concatenate形成输出。

搜索结束后会留下两个超参待定。分别是每一层中normal cell的数量N和初始输入的feature map的大小F。这两个参数给scale up整个网络留下了接口。

最后解释一下search space提供的所有候选操作：

- None
- 3×3 , 5×5 , 7×7 sep (separable conv, 即point wise+element wise的组合)
- 3×3 avg/max pooling
- 3×3 dilated (空洞) sep conv
- $1 \times 7 + 7 \times 1$ conv

Results

1. 搜索出的结果

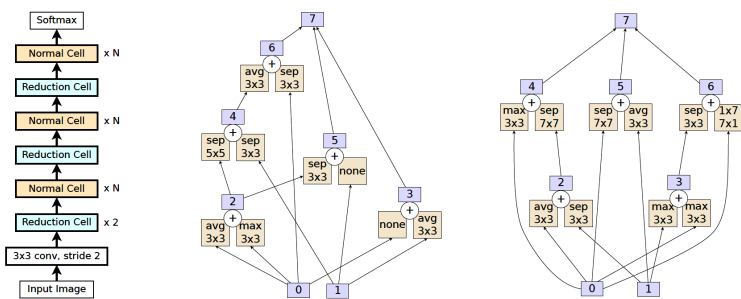


Figure 5: AmoebaNet-A architecture. The overall model [53] (LEFT) and the AmoebaNet-A normal cell (MIDDLE) and reduction cell (RIGHT).

上图为本文中用于性能测试的AmoebaNet-A

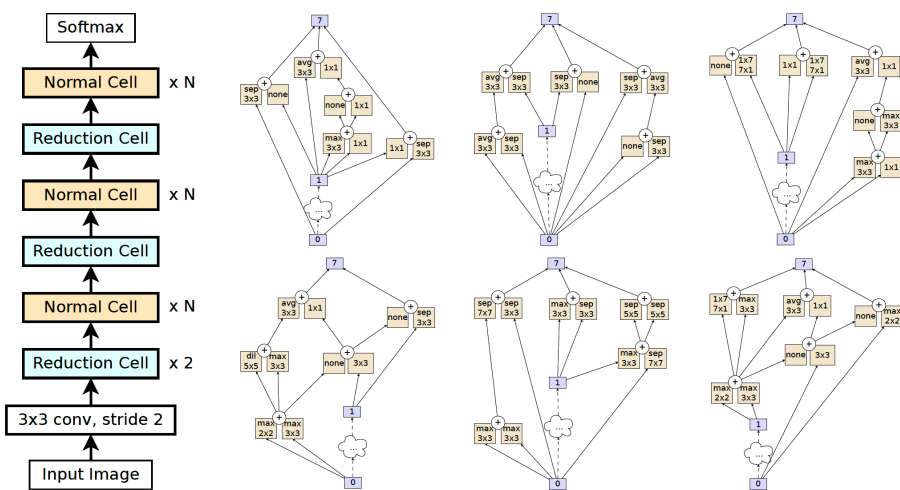


Figure D-1: Architectures of overall model and cells. From left to right; outline of the overall model [53] and diagrams for the cell architectures discovered by evolution: AmoebaNet-B, AmoebaNet-C, and AmoebaNet-D. The three normal cells are on the top row and the three reduction cells are on the bottom row. The labeled activations or hidden states correspond to the cell inputs (“0” and “1”) and the cell output (“7”).

上图为另外三种可行的结构B、C、D，在后续的工作中会用到

2. 网络的性能表现

Table 2: ImageNet classification results for AmoebaNet-A compared to hand-designs (top rows) and other automated methods (middle rows). The evolved AmoebaNet-A architecture (bottom rows) reaches the current state of the art (SOTA) at similar model sizes and sets a new SOTA at a larger size. All evolution-based approaches are marked with a *. We omitted Squeeze-and-Excite-Net because it was not benchmarked on the same ImageNet dataset version.

Model	# Parameters	# Multiply-Adds	Top-1 / Top-5 Accuracy (%)
Incep-ResNet V2 [43]	55.8M	13.2B	80.4 / 95.3
ResNeXt-101 [47]	83.6M	31.5B	80.9 / 95.6
PolyNet [50]	92.0M	34.7B	81.3 / 95.8
Dual-Path-Net-131 [7]	79.5M	32.0B	81.5 / 95.8
GeNet-2 [46]*	156M	—	72.1 / 90.4
Block-QNN-B [51]*	—	—	75.7 / 92.6
Hierarchical [29]*	64M	—	79.7 / 94.8
NASNet-A [53]	88.9M	23.8B	82.7 / 96.2
PNASNet-5 [28]	86.1M	25.0B	82.9 / 96.2
AmoebaNet-A*	86.7M	23.1B	82.8 / 96.1
AmoebaNet-A*	469M	104B	83.9 / 96.6

如图，确实达到了当时ImageNet上up-to-date的水平。

Insights

基于启发式学习的网络搜索新工作。

本推送中重点介绍了网络搜索的搜索空间和搜索结果。

但是文章的实际价值集中在更迅速、更高效地新型NAS技术。利用启发式方法想来是高效率的代名词，正如利用RL是低效率烧卡的代名词一样。如果对文章中启发式算法设计细节感兴趣，可以进一步参照原文。